

미어캣 위원회

규율은 세울 때가 아니라 흔들릴 때 필요하다

AI 에게 무엇을 맡기고 무엇을 맡기지 않을지를
설계하고, 실측으로 정한 8 주의 기록

엔진 하나 · 분야 셋 — 새 분야를 열어도 엔진 코드는 0 줄

연금

대출

충동구매

위원 다섯

AI 에이전트 다섯 · 각자 다른 눈

시장분석가

원칙검사관

과거기록관

반론자

의장

반론자만 다른 위원의 출력을 읽는다
— 전부 대화시키면 합의가 되고, 합의는 추천이 된다

02 규율은 세울 때가 아니라 흔들릴 때 필요하다

정보 · 대조 · 반론 — 그리고 결정은 사용자

정보

대조

반론


결정은 사용자가 합니다

챗봇 그 자리에서 지어낸 답

위원회 저장된 원칙과 대조한 답

오히려 챗봇보다 더 많이 물어봅니다 .
그 대신 답이 흔들리지 않습니다 .


회사에는 한도가 있는데, 제 계좌에는 없더군요.



실제 화면 — 「정보 · 대조 · 반론만 드립니다 . 결정은 당신이 합니다」

03 전체 흐름 — 색깔이 곧 설계입니다

파란 실선 = 코드 (결정론) · 붉은 점선 = AI · 초록 = 선언 파일



판정이
파란색입니다

코드가 확정하는 원칙 다섯

- P1 섹터 집중
- P2 분할 집행
- P3 물타기
- P4 냉각
- P5 변경 사유

AI 는 양쪽 끝에만 있습니다 —
읽는 자리와 , 말로 옮기는 자리 .

04 여정 — 가설 하나와 벽 둘

맞았던 가설 · 아무도 안 쓴 입력 양식 · 끝나지 않던 단어 목록

가설

엔진 + 설정

판정은 코드가,
말은 AI 가

새 분야를 열어도
엔진 코드는 0 줄

벽 ①

입력 양식

칸을 채워 넣는
딱딱한 서식

아무도 안 쓸 것 같은
물건이 되어 버렸다

벽 ②

단어 목록

말을 낱말로
받아내려 했다

1 만 줄이 되어도
끝이 없었다

지금

순서를 뒤집었다

AI 가 먼저 읽고,
코드가 검사한다


읽기는 무한하고
검사는 유한하다

끝나지 않는 목록이었습니다

규율 하나 — 단어를 목록에 더해서 증상을 없애지 마라.
같은 자리에서 다음 겹이 또 죽습니다. 총을 못박기 전에 또 고치지 않습니다.

접수층 — 사람 말을 판정이 쓸 값으로

여기가 오늘 이야기의 절반입니다



말 → 접수층 → 확정된 칸만 담긴 요청서

읽기는 무한하고 검사는 유한하다

사람 말은 끝이 없으니 읽는 일은 모델이 맡습니다 .
그런데 제가 만든 가드레일이 거절하는 이유는 딱 세 가지뿐입니다 .

1 모양이 안 맞음

숫자 자리에 글자가 왔다

2 목록에 없음

선언 파일의 후보에 없는 값이다

3 말과 다름

사용자가 한 말과 값이 어긋난다

셋뿐이라 시험지로 잠글 수 있습니다 — 그래서 떼어낼 수 있는 부품이 되었습니다 .

총 일곱 — 줄 앞에 누가 했는지 찍합니다

```

PS C:\Claude\meerkat-committee> bun run tools/intake-trace.ts --fixture
미어캣 접수 추적 로그 - 배치 879
모드: --fixture(모델 호출 0) · repeat 1

— pension-kr · 연금 · 몫 돌(거절·가름 섞임) —
문장: "반도체 100만원 사고, 코인 300만원 준버"
[1] 분해 LLM - 조각 5개(칸 지목 5개) · 몫 표시 1,2 · leftover 1개
[2] 배분 코드 - 몫1 - instrument=반도체, amount=100만원 / 빈칸 direction
[2] 배분 코드 - 몫2 - (잔 칸 없음) / 빈칸 direction, instrument, amount
[3] 검사 코드 - 통과 2건 · 거부 2건
· 몫2 instrument - not_in_set (후보 5개 중 못 찾음) "'코인' is not among the candidates"
· 몫2 direction - not_in_set (후보 2개 중 못 찾음) "'준버' is not among the candidates"
[3.5] 가름 코드 - 승격 1건 - 몫1.direction=매수 · 여전히 확신 아님 몫1.direction(partial)
[4] 되묻기 코드 - "다음 중 하나를 가리켜 말해 주세요." (칸: instrument#2) - ★모델이 아니라 사람에게 묻는다
[5] 되읽기 코드 - "이렇게 읽었습니다. 매수(「매수」로 들었는데, 확실치 않아요.) 종목 반도체 금액 100만원. 연금 매매
에서 제가 아는 말이 아...
[6] 화면 코드 - 칸 6개(선택지 있는 칸 4개)
[7] 세션 코드 - 몫 2개 · 판정 입력(봉투) 해시 a9ee122b...

— loan-kr · 대출 · shape·echo_mismatch 표본 —
문장: "신용대출 3000만원 받으려구요"
[1] 분해 LLM - 조각 2개(칸 지목 2개) · 몫 표시 1 · leftover 0개
[2] 배분 코드 - 몫1 - (잔 칸 없음) / 빈칸 loanType, amount, period, when
[3] 검사 코드 - 통과 0건 · 거부 2건
· 몫1 loanType - shape "number is not a string"
· 몫1 amount - echo_mismatch "no surface form for this amount in the cited fragment"
[3.5] 가름 코드 - 승격 없음(확신 아님 값 0건)
[4] 되묻기 코드 - "어떤 대출인지 말씀해 주세요." (칸: loanType) - ★모델이 아니라 사람에게 묻는다
[5] 되읽기 코드 - "이렇게 읽었습니다. 아직 못 들은 것이 있어요: 종류, 금액"
[6] 화면 코드 - 칸 4개(선택지 있는 칸 1개)
[7] 세션 코드 - 몫 1개 · 판정 입력(봉투) 해시 4f53cda1...

— impulse-kr · 충동구매 · shape 표본(선택 칸이라 되묻지는 않는다) —
문장: "전자기기 5만원 살까 말까 고민했어요, 목걸이 사기로 했어요"
[1] 분해 LLM - 조각 4개(칸 지목 4개) · 몫 표시 1,2 · leftover 0개
[2] 배분 코드 - 몫1 - item=전자기기, hesitated=망설였어요 / 빈칸 amount, when
[2] 배분 코드 - 몫2 - item=목걸이 / 빈칸 amount, when, hesitated
[3] 검사 코드 - 통과 3건 · 거부 1건
· 몫1 amount - shape "string is not a number"
[3.5] 가름 코드 - 승격 없음(확신 아님 값 0건)
[4] 되묻기 코드 - 더 물을 것 없음(settled)
[5] 되읽기 코드 - "이렇게 읽었습니다. 물건 전자기기 망설임 망설였어요, 물건 목걸이. 다르게 읽었으면 고쳐 주세요."
[6] 화면 코드 - 칸 8개(선택지 있는 칸 2개)
[7] 세션 코드 - 몫 2개 · 판정 입력(봉투) 해시 c2326253...
PS C:\Claude\meerkat-committee>

```

막힐 때마다 이름이 붙습니다 — not_in_set · shape · echo_mismatch, 셋뿐입니다

첫 층만 AI, 나머지 여섯은 코드입니다

이름표만 돌려준다

모델은 「어느 칸인지」만 말하고,
값은 코드가 채웁니다. 필터로 막는 게
아니라 권한을 안 줍니다.

되묻기는 사람에게

막힌 칸 하나만 사용자에게 묻습니다.
Self-Correction 을 모델 안이 아니라
사람과의 왕복에 두었습니다.

갈래는 코드가 친다

후보를 벌렸다가 코드가 쳐냅니다 —
여기가 ToT 의 얇은 버전입니다.

07 AI 가 일하는 자리 — 일곱 곳

그리고 한 곳에만 쓰지 않기로 했습니다

1 문장 분해 AI

한 문장에서 여러 건을 뽑고, 어느 칸에 무엇이 들어갈지 읽는다

「반도체 300 팔고 로봇 200 사려구」 → 몫 2개 · 칸 6개

★ 읽기는 무한하다 — 사람 말은 끝이 없으니 여기는 모델이 읽는다

위원 다섯 — 에이전트 다섯 AI × 5

각자 다른 프롬프트 · 다른 입력 · 다른 눈

2 시장분석가

시장 맥락을 붙인다

3 원칙검사관

확정된 판정을 설명한다

4 과거기록관

지난 심의를 찾아 인용

5 반론자

★ 다른 위원 출력을 읽고 반박 — 에이전트 사이 대화

6 의장

정리한다 — 결론은 내지 않는다

★ 그룹챗을 검토했고 일부러 안 골랐다 — 합의로 수렴하면 그 순간 「추천」이 된다

서술은 대화여도 되지만 판정은 대화의 산물이 되면 안 된다. 그 경계를 코드로 그었다

7 이 제품을 만든 공장 AI × N

판단 자리 Opus 1 + 일꾼 Sonnet N · 워크트리 4 레인 병렬 · 큐 파일 하나로 배분

배치가 끝나면 스스로 다음 배치를 큐에 쓴다 · 게이트 통과를 배치가 스스로 확인

파수꾼이 5분마다 살아 있는지 보고 죽었으면 알아끼운다 — 배치 번호가 900 번에 이르렀다

★ 제품 안에서는 자율성을 억제했지만, 만드는 과정에서는 극단적으로 자율적으로 굴렀다

2026-09-09, 그 공장의 손 하나가 죽었다. 고친 방법은 「되살리기」가 아니라 「없어도 되는 문을 새로 내기」였다

쓰지 않기로 한 한 곳

원칙 위반 판정

처음엔 모델에 맡겼다. 그리고 실측했다:

모델에 맡겼을 때 — 라이브

510회 → 흔들림 29건

코드로 옮긴 뒤 — 커널 대조

불일치 0

★ 검사는 유한하다

거부 이유가 셋뿐이라 골든 케이스로 잠글 수 있다

그래서 한 문장

AI 를 안 쓴 것이 아니라,
어디에 쓸지를 실측으로 정했다.

일곱 곳에 쓰고 한 곳에 쓰지 않았다.

그 한 곳을 정한 실측이

이 프로젝트의 알맹이다.

일곱 곳에 쓰고
한 곳에 안 썼습니다

일곱째 = 이 제품을 만든 공장

모델 여럿 · 작업 공간 넷 병렬

스스로 다음 일을 큐에 넣고

감시 프로세스가 되살린다

배치 번호 900 번대

제품 안에서는 자율성을
억제했지만,
만드는 과정에서는 극단적으로
자율적으로 굴렸습니다.

안 쓰기로 한 한 곳 = 원칙 위반 판정. 랭그래프 · 랭체인은 붙여 볼까 하다 안 쓰기로 했습니다 — 랭퓨즈로 추적은 되지만, 재현은 어느 모델 안에서도 보장되지 않습니다.

08

숫자 두 개 — 그리고 이 둘은 같은 축이 아닙니다

왼쪽은 재현성 , 오른쪽은 일치성 — 서로 다른 것을 잴 것입니다

모델에 맡겼을 때 — 라이브

510 회

→ 흔들림 29 건

재현성

같은 말을 다시 넣으면
같은 답이 나오는가

다른
축

코드로 옮긴 뒤 — 두 구현 대조

38 건

→ 어긋남 0 건

일치성

옛 코드와 새 코드가
같은 정답지에서 같은 답을 내는가

2026-08-05 게이트웨이 실측 · 2026-08-29 재현성 166 문장 510 회 · 2026-09-10 라이브 3 회 — 판정 입력 해시 동일 · 판정 엔진 1 ↔ 2 커널 대조

재현되지 않는 판정은 판정이 아닙니다 .

배운 것과 , 아직 못 한 것

못 한 것을 못 했다고 말하는 칸을 제품 안에도 만들었습니다

배운 것

● 「모른다」 에 이름을 준다

위반 · 위반 아님 · 그리고 검사 대상 아님 .
주택담보대출이 하나로 안 좁혀지면 그 칸을
채우지 않고 심의를 멈춥니다 .

● 읽기는 무한 / 검사는 유한

AI 자리와 코드 자리를 가르는 잣대가
되었습니다 .

● 단어를 더해 증상을 없애지 마라

목록을 키우는 대신 층의 순서를 바꿉니다 .

아직 못 한 것 · 다음

● 부품은 만들었고 , 화면이 못 따라왔다

설계가 틀린 게 아니라 배선이 안 끝났습니다 .
오늘 시연은 이전 판으로 합니다 .

● 판정 엔진 1→2 와 접수층을 못 이었다

각각은 서고 , 사이가 비어 있습니다 .


● 팩 스튜디오

회사가 내부 규정을 말로 설명하면
설정 파일도 항목 구조도 AI 가 만듭니다 .

AI 에게 무엇을 맡기고 무엇을 맡기지 않을지 , 저는 감이 아니라 실측으로 정했습니다 .

10 부록 — 접수층 총 일곱

발표에서는 넘기지 않습니다



대조 시험

- 정답지 38 건
- 판정 엔진 1 ↔ 2 커널 대조
- 어긋남 0 건

재현성 실측

- 라이브 510 회
- 흔들림 29 건
- 2026-08-29

원칙 다섯

- P1 섹터 집중
- P2 분할 집행
- P3 물타기
- P4 냉각
- P5 변경 사유